

krigagem com deriva externa aplicado a precipitações anuais médias do Brasil em 2023

Nicolas Zafred Paiva

Alex Monito Nhancololo

2026-02-22

Índice

0.0.1	INTRODUÇÃO	1
0.0.2	MATERIAIS E MÉTODOS	2
0.0.3	RESULTADOS	3
0.0.4	CONCLUSÕES E CONSIDERAÇÕES FINAIS	9
	REFERÊNCIAS	10

0.0.1 INTRODUÇÃO

A estatística espacial pode ser dividida em três áreas: dados de área, que tratam de variáveis conectadas com áreas e regiões no espaço; dados pontuais, que ocorrem em pontos do espaço e podem estar associados a “marcas” (números ou nome do evento); e a área da geoestatística, onde temos uma série de dados coletados em pontos de uma determinada região e queremos fazer uma estimativa da variável de interesse em todo o espaço de estudo, supondo à priori que a variável em estudo é espacialmente correlacionada.

Existem alguns métodos de se realizar a estimativa de uma variável em geoestatística, como a interpolação do inverso do quadrado da distância. Contudo, neste trabalho estaremos interessados no método da krigagem que foi desenvolvido em aplicações voltadas a área de mineração pelo engenheiro Daniel Krige. Esse método utiliza o modelo obtido pela semivariância empírica para avaliar os pesos de cada ponto de uma malha de predição, e com isso é capaz de realizar a estimativa espacial com base em alguns pontos amostrais do território. (Scalon (2024))

O presente trabalho propõe-se a analisar as precipitações anuais médias do Brasil no ano de 2023, a partir dos dados das estações meteorológicas do INMET. Assim como os efeitos da vegetação superficial na qualidade da precisão com o método de krigagem com deriva externa.

0.0.2 MATERIAIS E MÉTODOS

Os dados meteorológicos foram agrupados e suas respectivas medias foram utilizadas para o período de um ano, isto foi feito com o intuito de eliminar os efeitos climáticos das estações do ano, oriundos da inclinação do eixo da Terra em relação ao plano de translação ao redor do sol. Assim como nos dados de precipitação, os dados de vegetação foram coletados ao longo de um ano e suas média foram calculadas.

Os dados climáticos do Brasil utilizados neste trabalho foram extraídos a partir da biblioteca “BrazilMet” (Filgueiras et al. (2026)), para todas as estações meteorológicas administradas pelo INMET para o período de 01/01/2023 a 31/12/2023. Em seguida os dados foram agrupados pela função `aggregate()`, com o objetivo de calcular a precipitação média de cada estação para o período escolhido. Após isto, os dados tiveram de ser associados a um sistema de coordenadas (Pebesma; Bivand (2023)), optamos pelo sistema 5880 (“SIRGAS 2000 / Brazil Polyconic”) que opera na unidade de metros.

Em seguida, utilizamos a função `read_country(year=2020)`, do pacote (Pereira; Goncalves (2024)), para extrair o contorno do território brasileiro, que servira como limite para a nossa área de análise. Da mesma forma que anteriormente, o contorno do Brasil foi transformado para o sistema de referência 5880.

Antes de realizar a krigagem com deriva externa, realizamos a krigagem ordinária para os dados das 562 estações meteorológicas. A krigagem necessita de um modelo para a semivariância em função da distância, para isto, utilizamos a função `autofirVariogram()`, da biblioteca (Hiemstra et al. (2008)). Os gráficos dos semivariogramas, assim como todos os gráficos deste trabalho, foram gerados através da função `ggplot()`, oriunda do pacote (Wickham (2016)), bem como a biblioteca (Dunnington (2025)), utilizada para inserir as direções norte-sul e a escala dos mapas, as tabelas foram geradas pelo pacote (Iannone et al. (2026)).

A malha de previsão (o termo previsão utilizado ao longo de todo este trabalho refere-se a interpolação espacial com base em dados de apenas alguns pontos, não se trata de previsões temporais) utilizada é comum a ambos os métodos preditivos empregados, inicialmente foi definido uma precisão de 10 km, porém, devido a limitações computacionais, a precisão teve de ser reduzida para 20 km. No geral, malha foi criada a partir dos seguintes comandos: `st_make_grid()` (para a criação do reticulado com base no contorno do brasil), `st_as_sf()` (que transforma a malha em um objeto do tipo sf) e a função `st_intersection()` (que recorta da malha de predição as células fora do contorno do Brasil).

O modelo do semivariograma obtido foi então utilizado como o modelo para a função `gstat()` (Gräler; Pebesma; Heuvelink (2016)), que realiza a predição dos dados de precipitação para todas as células da malha de predição definida. Com base nessa malha de previsão, pode-se construir o mapa da precipitação média anual de chuva, bem com o mapa de variância de cada célula.

Para inserir a variável vegetação da superfície no intuito de auxiliar a previsão da variável de interesse (precipitação em mm), utilizaremos a krigagem com deriva externa. Este método de predição é semelhante a krigagem universal, com a diferença de que se utiliza uma variável espacialmente para tentar realizar a previsão, e não apenas as coordenadas geográficas.

A fim de tentar melhorar o modelo preditivo, resolvemos utilizar uma variável de vegetação, os dados de vegetação foram coletados a partir da biblioteca (rgee: Google Earth Engine for R) (Aybar; Stigler (2026)), mais especificamente a partir da base de dados “MODIS/061/MOD44B”, dentro da qual localiza-se a variável “Percent_Tree_Cover”, que foi coletada no período que compreende o ano de 2023. O pacote rgee gera um arquivo do tipo “.tif”, que foi lido dentro do R com o auxílio da biblioteca (Hijmans (2026)), a função `extract()` foi a responsável por extrair os pontos da variável vegetação nas coordenadas das estações meteorológicas, enquanto a função `project()` realizou a projeção dos dados para o mesmo sistema de referência dos dados das estações e o contorno do território do Brasil.

Existem uma grande diferença de precisão entre a malha de predição definida e a resolução dos dados de vegetação (ndvi), o primeiro se encontra na escala de 20km, enquanto o segundo tem uma resolução de ~250m. Para contornar este problema realizamos a média dos dados de vegetação em torno do polígono ou ponto de interesse. Assim, para o cálculo do modelo do semivariograma, retiramos a média dos dados de cobertura vegetal para um raio de 10km (para contornar a possibilidade de dados faltantes nas localizações das estações meteorológicas), o mesmo foi feito para os dados das células da malha de predição.

Com base nestes dados, obtivemos o modelo do semivariograma pela função `autofitVariogram()`, com a covariável da vegetação, o resultado foi inserido na função `gstat()` para a realização da krigagem com deriva externa.

Enfim, finalizamos a análise com a verificação por validação cruzada (Nhancololo; Scalon; Alencar (2026), seção 3.14.1 Validação Cruzada) para os dois modelos de predição desenvolvidos neste trabalho. A validação cruzada utilizada baseia-se na ideia de retirar um dado observado do conjunto e tentar aplicar o modelo de predição com os dados restantes para calcular o valor da variável de interesse na localização do ponto retirado, isto é realizado para todas as amostras do conjunto de dados.

0.0.3 RESULTADOS

Inicialmente, foi verificado a distribuição das 562 estações meteorológicas do INMET ao longo do território brasileiro (Figura 1). Uma inspeção visual das estações permite a observação de como as estações parecem estar igualmente espaçadas em algumas regiões (interior da região nordeste), enquanto em outras partes estão bem concentradas ao redor de algumas capitais (salvador, rio de janeiro e Brasília), já na região Nordeste as estações são bem dispersas umas em relação as outras.


Figura 1: Distribuição dos pontos de amostragem das estações meteorológicas do INMET.



Fonte: Elaborado pelos autores (2026).


Os gráficos da semivariância para os dois tipos de krigagem (ordinária e com deriva externa) utilizados encontram-se nas Figura 2 e Figura 3, o ajuste (Hiemstra et al. (2008)) selecionou o modelo Stein Matérn para o ajuste dos dados experimentais para ambas as abordagens. É interessante notar a diferença de alcance e patamar dos dois ajustes, além da concavidade invertida no começo da curva (para pequenas distâncias).

Figura 2: Semivariograma da krigagem ordinária.



FONTE: Elaborado através da biblioteca (Hiemstra et al. (2008)).

Figura 3: Semivariograma da krigagem com deriva externa.




FONTE: Elaborado através da biblioteca (Hiemstra et al. (2008)).

A partir do ajuste obtido para o semivariograma empírico, aplicamos os dados de precipitação na função `predict(gstat())` (para a krigagem ordinária), obtendo assim a previsão da preci-

pitação média em todas as células da malha de previsão definida anteriormente. O resultado destas previsões, bem como a variância obtida pelo modelo, encontra-se na Figura 4.

Vê-se a esquerda a precipitação média anual prevista para todo o território, e na direita temos a variância da previsão. É interessante notar como as menores precipitações ocorrem em geral na região do nordeste, por outro lado, as maiores precipitações médias se encontram ao norte da região norte e na região sul (estado de Santa Catarina e norte do Rio Grande do Sul). As maiores variância obtidas pela previsão se localizam nas mesmas áreas com uma baixa densidade de estações meteorológicas na região norte (vide Figura 1).


Figura 4: Mapas de predição e variância para a precipitação de chuva média anual, no ano de 2023, para a krigagem ordinária com precisão de 20 km.



FONTE: Elaborado pelos autores (2026).

Ao adicionar os dados da vegetação na krigagem com deriva externa, obtemos o gráfico da Figura 5. O comportamento dos extremos das escalas é semelhantes, o interior do nordeste continua apresentando os menores índice de precipitação, enquanto o norte e o estado de Santa Catarina apresentam os maiores índices de precipitação. A mudança mais nítida ocorre no mapa de variância, os erros mais acentuados na região do extremo norte do Brasil deixam de ser os mais elevados, contudo neste modelo de previsão a região de maior variância ocorre na região próxima das coordenadas (10°S, 50°W). Contudo é necessário observar que a escala de variância duplica com o ajuste com a vegetação, indo de 1 mm a 3 mm na ordinária, para 2 mm a 6 mm no novo modelo.

Figura 5: Mapas de predição e variância para a precipitação de chuva média anual, no ano de 2023, para a krigagem com deriva externa com precisão de 20 km.



FONTE: Elaborado pelos autores (2026).

Com a validação cruzada, obtivemos os indicadores (Tabela 1). Com a krigagem de deriva externa, o viés e a precisão melhoram ligeiramente, mas o índice MSDR aumenta em relação a krigagem ordinária.

Tabela 1: Indicadores da validação cruzada para ambas as previsões utilizadas.


Indicador	Krigagem ordinaria	Krigagem com deriva externa (vegetação)
Mean error (Viés)	0.0012	0.0010
RMSE (Precisão)	1.3830	1.3618
MSDR (Calibração)	1.1950	1.3113

FONTE: Elaborado pelos autores (2026).

Os últimos resultados obtidos se encontram nas Figura 6 e Figura 7, nas quais mostram-se os gráficos de dispersão da variável predita (krigagem) em função da variável observada (dados das estações), juntamente com os histogramas dos resíduos (erro) normalizados e o seu ajuste normal. No intuito de se ter uma melhor compreensão da eficácia de ambos os modelos,


realizamos o cálculo dos coeficientes de determinação, onde pode-se observar que o coeficiente para a krigagem com ajuste da vegetação é maior, o que indicaria que o segundo modelo consegue explicar uma maior quantidade de dados observados, considerando apenas os pontos amostrais.

Figura 6: Gráfico de dispersão da variável predita e observada (a esquerda), e histograma dos resíduos padronizados (a direita), para krigagem ordinária.



FONTE: (Nhancololo; Scalon; Alencar (2026), seção 3.14.1 Validação Cruzada)

Figura 7: Gráfico de dispersão da variável predita e observada (a esquerda), e histograma dos resíduos padronizados (a direita), para krigagem com deriva externa.



FONTE: (Nhancololo; Scalón; Alencar (2026), seção 3.14.1 Validação Cruzada)

0.0.4 CONCLUSÕES E CONSIDERAÇÕES FINAIS

As medidas meteorológicas não são medidas em todo o território brasileiro, vastas áreas tem uma baixa cobertura de estações meteorológicas (especialmente a região norte), isto dificulta a predição de dados de precipitação em certas regiões com base nos dados amostrais disponíveis.

A predição da variável de interesse analisada (precipitação de chuva em mm), foi realizada em todo o território brasileiro com base no método de interpolação da krigagem ordinária, isto resultou em uma estimativa boa para as áreas com maior concentração de estações, mas apresentou um erro maior nas áreas ao norte dos estados do Amazonas e Roraima, justamente onde existe a menor presença de dados observados.

No intuito de suprir essa falta de informação, inserimos a variável vegetação superficial no modelo de predição. Ao contrário dos dados das estações, essa variável é muito bem conhecida (precisão de ~ 250m) em razão dos dados de satélite. Com isto, foi possível aplicar a krigagem com deriva externa, utilizando-se os dados de vegetação, gerando assim um modelo de predição visualmente semelhante ao obtido com a krigagem ordinária, mas seu mapa de variância mostrou uma escala de erro significativamente maior.

No geral, pode-se afirmar a que os dados de vegetação não se mostraram um fator fundamental para a melhora na predição dos dados de precipitação de chuva, o que significa que ambos os

modelos são equivalentes entre si. Análises posteriores, que incorporem dados de altitude, temperatura e índices de evapotranspiração em escala nacional talvez consigam resultados mais satisfatórios.

REFERÊNCIAS

AYBAR, Cesar; STIGLER, Matthieu. **rgee: R Bindings for Calling the 'Earth Engine' API**. [S.l.: S.n.].

DUNNINGTON, Dewey. **ggspatial: Spatial Data Framework for ggplot2**. [S.l.: S.n.].

FILGUEIRAS, Roberto *et al.* **BrazilMet: Download and Processing of Automatic Weather Stations (AWS) Data of INMET-Brazil**. [S.l.: S.n.].

GRÄLER, Benedikt; PEBESMA, Edzer; HEUVELINK, Gerard. **Spatio-Temporal Interpolation using gstat**. **The R Journal**, v. 8, p. 204–218, 2016.

HIEMSTRA, P. H. *et al.* Real-time automatic interpolation of ambient gamma dose rates from the Dutch Radioactivity Monitoring Network. **Computers & Geosciences**, 2008.

HIJMANS, Robert J. **terra: Spatial Data Analysis**. [S.l.: S.n.].

IANNONE, Richard *et al.* **gt: Easily Create Presentation-Ready Display Tables**. [S.l.: S.n.].

NHANCOLOLO, Alex Monito; SCALON, João Domingos; ALENCAR, Airlane Pereira. **Introdução à Estatística Espacial: Teoria e Aplicações com R**. Disponível em: <<https://introducao-a-estatistica-espacial.netlify.app/>>.

PEBESMA, Edzer; BIVAND, Roger. **Spatial Data Science: With applications in R**. [S.l.]: Chapman and Hall/CRC, 2023.

PEREIRA, Rafael H. M.; GONCALVES, Caio Nogueira. **geobr: Download Official Spatial Data Sets of Brazil**. [S.l.: S.n.].

SCALON, J. D. **Análises de dados espaciais com aplicações em R**. Lavras: Ed. UFLA, 2024.

WICKHAM, Hadley. **ggplot2: Elegant Graphics for Data Analysis**. [S.l.]: Springer-Verlag New York, 2016.